

2024 반도체 솔버톤 대본

(슬라이드 1) 표지

안녕하십니까. 믿음을주세요 팀의 팀장 변지환입니다.

오늘 제가 발표드릴 주제는,

‘랜덤화 기법 및 해석 가능한 인공지능을 활용한

QLC 낸드플래시 데이터 신뢰성 개선에 관한 연구’입니다.

QLC에서 발생하는 복잡한 **데이터 신뢰성 문제**를 어떻게 해결할 수 있을지,

그리고 **해석 가능한 AI**를 통해 ‘왜 그런 문제가 발생하는지’를 분석해낸 과정을

자세히 공유해보도록 하겠습니다.

(슬라이드 2) Executive Summary

먼저, 오늘 발표의 **핵심**을 간략히 요약하겠습니다.

QLC는 셀 하나에 4비트를 저장할 수 있어 저장 용량이 증가했지만,

전압 마진이 좁아져 **간섭**과 **열화** 같은 문제가 심각합니다.

이러한 간섭과 열화 문제로 인해 데이터 오류가 발생합니다.

이를 해결하기 위해 총 3가지 Task를 설정했습니다.

첫번째로, **Task 1**, 즉 **랜덤화 기법**입니다.

저희는 LFSR 기반 랜덤화 기법을 적용함으로써 **데이터 패턴 의존성**을 완화시켰습니다.

두 번째로, **Task 2**는 **열화현상 모델링**입니다. 여기서는 **RTN**, **CCI**, **리텐션**과 같은 **물리적 노이즈 요인**을 종합적으로 모델링하여

복합적인 열화 현상을 파악하는 데 중점을 두었습니다.

마지막으로, **Task 3**, **해석 가능한 AI**입니다. 기계학습 모델을 활용하여 **오류 발생**을 예측하고, **SHAP**과 **LIME** 같은 기법을 통해 **오류가 왜 발생했는지**를 설명할 수 있도록 했습니다.

결론적으로, 이 연구는 단순히 오류를 줄이는 것을 넘어, **오류 메커니즘**을 해석하여 **실무 반도체 엔지니어들에게 가이드라인**을 제시하는 데 주된 의의가 있습니다.

1. 서론 (연구 배경 설명)

(슬라이드 3) 메모리 반도체 시장 현황

최근 메모리 반도체 시장에서 QLC는 고집적화를 달성하기 위해 널리 주목받고 있습니다.

(슬라이드 4) QLC의 발전

하지만, 한 셀에 **4비트**를 저장하기 위해서는 **16단계 전압**을 구분해야 하므로 **전압 마진**이 매우 협소해집니다.

이는 미세한 **셀 간 간섭**이나 **전하 누설(리텐션)**, **읽기 방해** 등에 의해 오류가 쉽게 발생하게 만들고, 결과적으로 **데이터 신뢰성 문제**가 커집니다.

(슬라이드 5) 데이터 신뢰성 문제

이 그림에서 보시는 것처럼, QLC에서는 그림에 해당하는 하나의 Victim cell이 주변 여러 셀에 의해 영향을 받습니다.

(슬라이드 6) 데이터 열화 요인

다음으로, QLC에서 발생하는 세 가지 주요 열화 요인에 대해 설명드리겠습니다.

총 3가지로 **Data 리텐션** 현상, **P/E 사이클 증가**, **Read Disturb** 현상이 있습니다.

(슬라이드 7)

이러한 세 가지 열화 요인들은 서로 복합적으로 작용하여 QLC의 신뢰성을 저하시키는 주된 원인이 되고 있습니다.

기존 해결책(강력한 ECC, 간단 랜덤화 등)은 어느 정도 효과를 보였지만,

공정 미세화로 인한 비선형적 간섭 문제까지 완벽히 커버하기엔 한계가 드러났습니다.

따라서, 인공지능 기반 **사전 예측**과 **오류 원인 해석**을 결합한 새로운 접근이 필요하다고 판단했습니다.

(슬라이드 8)

앞서 말씀 드렸듯이 본 연구의 목적은 크게 세 가지입니다.

(슬라이드 9) (슬라이드 10)

그 중 첫번째 Task 1에 대해 설명드리겠습니다.

3. Task 1: 랜덤화 기법

(슬라이드 11) 랜덤화

지금 보시는 예시처럼, 특정 데이터 패턴에서는 심각한 문제가 발생할 수 있습니다.

예를 들어, '0000'이나 '1111'과 같이 동일한 값이 연속되는 경우를 보겠습니다.

이런 특정 패턴이 있을 때 특정 부분의 셀 마모가 빨라지고

전압 변동이 커질 수 있습니다.

특히 문제가 되는 것은, 이런 패턴이 있는 영역에서는

셀의 전압 변동폭이 커져서 **데이터 신뢰성에 치명적인 영향**을 미칠 수 있다는 점입니다.

따라서 저희는 이 문제를 해결하기 위해 **데이터 랜덤화** 기법을 도입하고자 합니다.

(슬라이드 12) LFSR(Linear Feedback Shift Register) 설계

랜덤화를 위해 LFSR을 사용했습니다.

LFSR는 비교적 간단한 논리회로로 **의사난수**를 생성하고,

이를 원본 데이터와 XOR 연산으로 결합합니다.

저희는 **16비트**와 **24비트**를 각각 구현해, 차이를 비교했습니다.

(슬라이드 13) LFSR 비교

저희는 LFSR 기반의 두 가지 랜덤화 방식을 비교 분석했습니다.

첫 번째로 **16비트**는 빠른 연산과 적은 메모리가 특징이며, 간단한 랜덤화가 필요할 때 적합합니다.

두 번째로 **24비트**는 높은 랜덤화 강도를 제공하지만 더 많은 시스템 자원이 필요하므로,

높은 랜덤성이 요구될 때 적합합니다.

(슬라이드 14) 하드웨어 구조

이제 저희가 설계한 랜덤화 하드웨어의 구조에 대해 설명드리겠습니다.

먼저 **Top 모듈인 NANDFlashTransformer**과

(슬라이드 15)

실제 데이터 변환을 수행하는 핵심 모듈인 **DataTransformer** 회로,

Reference Data를 생성하는 모듈인 **SeedGenerator** 회로가 있습니다.

(슬라이드 16)

이러한 하드웨어 구현의 성능을 검증한 결과,
약 $2938.85 \mu\text{m}^2$ 의 면적과 0.90 ns의 Critical Path Delay를 달성했습니다.
특히 주목할 점은, 매우 높은 동작 속도로도 안정적으로 작동하며
실제 구현 시에도 큰 오버헤드 없이 수행이 가능하다는 것입니다.

(슬라이드 17)

여기선 **랜덤성이 낮은 문장에 대해** 총 71,544 비트의 데이터를 대상으로 실험을 진행했으며,
원본 데이터와 두 가지 LFSR 방식을 비교 분석했습니다.

가장 주목할 만한 결과는 **시퀀스의 분포**입니다.

0 또는 1이 연속되는 덩어리를 시퀀스로 정의하였습니다.

원본 데이터에서는 0과 1의 시퀀스가 각각 약 13,000개로 불균형했던 반면,
두 LFSR 방식 모두 약 17,800개로 균등하게 분포되었습니다.

또한 **평균 연속 길이**가 원본의 2.75에서 2.01로 감소했는데,
이는 데이터가 더 균일하게 분산되었다는 것을 의미합니다.

결과적으로 16비트와 24비트 LFSR 모두 비슷한 수준의 랜덤화 성능을 보여주었으며,
이는 데이터 패턴 의존성을 효과적으로 줄일 수 있다는 것을 입증합니다.

(슬라이드 18)

다음으로는 일반적인 영어 문장에 대한 랜덤화 실험 결과를 보여드리겠습니다.

총 14,800비트의 일반 영어 텍스트 데이터를 분석했을 때,
흥미로운 점은

원본 데이터가 이미 어느 정도 랜덤한 특성을 보인다는 것입니다.

보시다시피 원본의 0과 1 시퀀스 수가 각각 약 3,770개로 거의 균등했으며,
평균 연속 길이도 1.96으로 낮은 수준을 보였습니다.

이는 자연어 텍스트의 경우 이미 어느 정도 랜덤성을 가지고 있어,
랜덤화 기법 적용의 효과가 상대적으로 적다는 것을 시사합니다

(슬라이드 19) Randomizer 한계

이처럼 랜덤화만으로 QLC의 복잡한 전압 분포 변화를 정교하게 예측하긴 불가능합니다.

LFSR는 결국 **의사난수**이기에 완전 무작위성을 보장하지 못하고,
특정 시드나 조건에서 예상치 못한 패턴이 나타날 수도 있습니다.

더 중요한 건, **셀 간 간섭, 리텐션, P/E 사이클 누적** 같은 물리적 요인을 반영해야 한다는 점입니다.

이에 따라, 저희는 **다음 단계**(Task 2와 3)에서 **열화 모델링**과 해석 가능한 **AI 예측**을 시도했습니다.

(슬라이드 20) (슬라이드 21)

4. Task 2: 열화 현상 모델링

다음으로 열화 현상 모델링입니다.

(슬라이드 22) 복합 노이즈 요소

Task 2는 QLC의 실제 물리적 열화를 모델링하는 단계입니다.

주요 노이즈·열화 인자는 **RTN, CCI, 리텐션**으로,

이들이 동시에 작용하면 **비선형적 문턱전압** 변동을 야기해 오류율이 상승합니다.

(슬라이드 23)

다음 식은 세 가지 노이즈 요소를 결합하여 도출된 문턱 전압 식입니다.

(슬라이드 24) GMM & 시뮬레이션

저희는 이러한 노이즈 요소를 GMM 형태로 근사해,

다양한 P/E 사이클, 리텐션 시간, 인접 셀 상태 등을 시뮬레이션으로 재현했습니다.

수많은 '가상 셀'에 대해 복합 노이즈가 누적되는 과정을 모델링함으로써 **대규모 데이터**를 얻었고,

이 데이터가 **다음 단계 AI** 학습의 기반이 됩니다.

핵심은, 단순히 '랜덤'이 아니라 실제 **물리적 현상을 고려하여 현실성**을 높였다는 점입니다.

(슬라이드 25)

LLR는 셀의 "0"과 "1" 확률 비율을 로그 스케일로 표현한 지표로,

LLR 변화가 크면 데이터 상태가 불안정해졌음을 의미합니다.

다음은 보면 PE 사이클과 리텐션 타임에 따른 LLR변화를 예상과 동일하게 관찰할 수 있었습니다.

(슬라이드 26) (슬라이드 27)

5. Task 3: 기계학습 기반 예측 모델 및 해석 가능한 AI 기법

지금부터 Task 3: 저희가 개발한 해석 가능한 AI 프레임워크에 대해 설명드리겠습니다.

(슬라이드 28) (슬라이드 29)

해석 가능한 AI는 학습 과정뿐만 아니라 **설명 인터페이스**를 통해

결과에 대한 이유를 사용자에게 명확히 전달합니다.

일반적인 AI는 결과 이유를 알기 어렵지만, XAI는 **결과 원인**을 설명해줍니다.

이를 통해 **AI 결과를 이해하고 신뢰할 수 있는 시스템**을 만드는 것이 XAI의 핵심 목표입니다.

(슬라이드 30) RAIN 프레임 워크

이제 저희가 제안한 **RAIN 프레임워크**를 소개하겠습니다.

RAIN은 **Reliability Assessment and Improvement framework for NAND flash**의 약자로,

QLC의 데이터 신뢰성을 평가하고 개선하는 데 중점을 둔 시스템입니다.

이 프레임워크는

- **열화현상 모델링**
- **AI 예측 모델**
- **SHAP/LIME을 통한 해석**으로 구성됩니다. 단순 예측을 넘어, **데이터 신뢰성 개선 전략**을 제안합니다.

결국, 이 프레임워크는 단순한 예측을 넘어, **데이터 신뢰성을 개선하기 위한 전략**을 제시하는 데 목적이 있습니다.

(슬라이드 31)

이 슬라이드는 AI 모델의 학습 및 성능을 시각화한 결과입니다.

- 첫 번째 그래프는 **Loss** 값입니다. 보시다시피, 학습이 진행될수록

Training, Validation Loss 모두 점차 감소하며 안정화되었습니다.

- **정확도, AUC(0.9 이상)** 모두 차례대로 우수한 결과를 나타냈습니다.

이 결과는 모델이 안정적으로 학습되었음을 시각적으로 확인할 수 있는 근거입니다.

(슬라이드 32)

다음은 혼동 행렬입니다.

이를 통해 MSB가 LSB에 비해 데이터 신뢰성에 더 중요한 영향을 미치는 것을 알 수 있습니다. LSB와 MSB의 예측 성능 차이를 기반으로 추가적인 보완 전략을 수립할 수 있습니다.

(슬라이드 33)

마지막으로 **ROC Curve**를 통해 모델의 전반적인 성능을 시각화했습니다.

- **MSB**의 AUC는 **0.95**, **LSB**는 **0.84**로 나타났습니다.
- LSB보다 MSB를 더 잘 예측하는 것을 볼 수 있습니다.

이처럼 ROC Curve는 모델이 얼마나 잘 예측하는지를 한눈에 보여주는 지표로 활용되었습니다.

(슬라이드 34)

이 슬라이드는 차례대로 **Random Forest**와 **XGBoost** 모델의 예측 확률 분포를 보여줍니다.

XGBoost가 Random Forest보다 높은 확률로 열화 발생을 예측하는 경향을 보입니다.

(슬라이드 35)

다음은 SHAP에 대한 설명입니다.

SHAP는 모델이 특정 예측을 내린 이유를 **기여도**로 표현하는 방법입니다.

즉, 모델의 예측을 인간이 이해할 수 있도록 시각적으로 설명하는 것입니다.

(슬라이드 36)

다음은 SHAP를 사용해 XGBoost 모델의 예측 결과를 분석한 **SHAP Summary Plot**을 보여드리겠습니다.

- 가장 중요한 특성은 **relative_llr_msb**로, 전체 모델 출력에 31~37%의 영향을 미쳤습니다.
- **리텐션_time**이나 **P/E cycles**는 영향력은 적고

neighbor3_llr_msb, **neighbor1_llr_msb** 등의 주변 셀의 LLR 값도 상위 기여 요인으로 나타났습니다.

이 결과를 통해 MSB의 LLR 값이 모델 성능에 중요한 역할을 하며, 주변 셀의 상태가 신뢰성 문제에 크게 기여한다는 점을 알 수 있습니다.

이러한 분석을 통해 **어떤 특징이 오류 발생 확률에 가장 크게 영향을 미치는지**를 한눈에 파악할 수 있었으며, 이는 엔지니어링 관점에서 매우 중요한 정보를 제공합니다.

(슬라이드 37)

다음으로 설명할 기법은 LIME입니다.

LIME은 지역적으로 모델 예측을 설명하는 데 초점을 맞춥니다.

이것은 개별 예측 결과에 대한 상세한 분석을 제공하며, 사용자가 구체적인 개선 방안을 이해하도록 돕습니다.

(슬라이드 38)

이제 **LIME**으로 해석한 결과를 보여드리겠습니다.

차례대로 Random Forest, XGBoost 모델의 해석입니다.

둘 다 유사한 특성 기여도를 보이지만, XGBoost는 일부 특성에서 더 강한 영향력을 보여줍니다.

이를 통해 엔지니어는 단순히 '**이 셀이 문제다**'라는 결과를 확인하는 데 그치지 않고,

'어떤 요인 때문에 이 셀이 문제인지'까지 명확히 알 수 있습니다.

이러한 방식은 문제의 원인을 정확히 파악하고, 효과적인 해결책을 도출하는 데 큰 도움을 줍니다.

(슬라이드 39)

이제, 연구를 통해 얻은 해석 결과가 실제 설계와 관리에 어떻게 활용될 수 있는지 말씀드리겠습니다.

첫째로, **MSB**가 특히 위험 요소로 작용한다는 점이 확인되었습니다.

이에 따라, MSB 영역에는 ECC를 더 강력하게 적용하거나,

페이지 할당 시 우선적으로 보정하는 전략을 제안할 수 있습니다.

둘째로, 인접 셀 간섭(CCI)의 영향을 무시할 수 없다는 점이 드러났습니다.

이를 바탕으로, 페이지 및 블록 레이아웃 설계 시 **노이즈 취약 구역**을 분산시키는 방안을 마련할 수 있습니다.

셋째로, **선택적 ECC/Refresh** 전략을 통해 오류 확률이 높은 영역에 자원을 우선적으로 투입하는 방식도 유효합니다.

(슬라이드 40)

결론적으로, 이 연구는 신뢰성 문제에 대해 랜덤화 기법과 해석 가능한 인공지능 framework를 이용하여

(슬라이드 41)

단순히 오류를 줄이는 데 그치는 것이 아니라, **어떤 부분을 중점적으로 관리해야 하는지에 대한 명확한 지침**을 제공한다는 점에서 중요한 의미를 가집니다.

(슬라이드 42)

6. 한계점, 향후 발전방향

하지만, 한계점도 분명히 존재합니다.

시뮬레이션 기반 모델링이기에,

실제 공정 편차, 환경 변수 등을 100% 반영하기 어려우므로,

실제 디바이스 테스트로 모델을 보완해야 합니다.

이러한 한계를 극복하기 위해서는, **실제 칩 데이터의 축적**이 필요합니다.

(슬라이드 43)

7. 결론

결론 요약

결론을 정리하자면, 본 연구는 다음과 같은 세 가지 주요 성과를 달성하였습니다.

첫째, **랜덤화 기법**.

둘째, **열화 모델링**

셋째, **해석 가능한 AI**입니다.

이를 바탕으로, **MSB 관리, 인접 셀 간섭 완화,**

그리고 **선택적 ECC/Refresh**와 같은

구체적이고 실효성 있는 전략을 제시할 수 있었습니다.

연구 의의

이 연구가 가지는 의의는 다음과 같습니다.

먼저, 단순히 ECC를 강화하거나 무작위화에 그치지 않고,

AI와 반도체 기술의 융합을 통해 문제를 **사전에 예측**하고,

그 **원인**을 해석할 수 있는 새로운 접근 방식을 제시했습니다.

또한, SHAP과 LIME을 통해 AI 모델의 '블랙박스' 한계를 극복하여,

모델의 판단 근거를 명확히 파악할 수 있게 되었고,

이는 실제 엔지니어링 개선으로 이어질 수 있습니다.

궁극적으로, 본 연구는 미래 메모리 신뢰성을 확보하기 위한 **새로운 패러다임**을 만들어 가는 데 중요한 역할을 할 것이라고 기대됩니다.

(슬라이드 44)

이상으로, 발표를 마치겠습니다.

감사합니다.